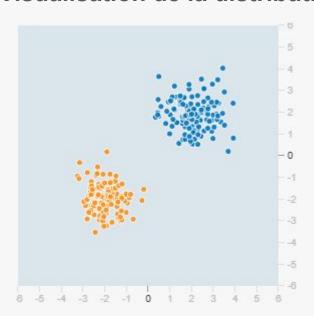


Tests de paramétrage des classifieurs à base de réseaux de neurones sur les différentes distributions de données

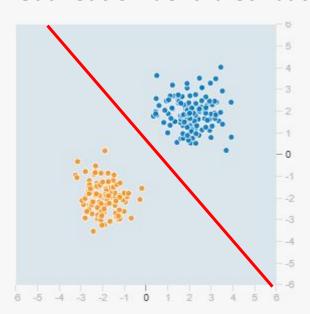
Visualisation de la distribution



Observation

Les deux classes sont séparées de façon linéaire.

Visualisation de la distribution



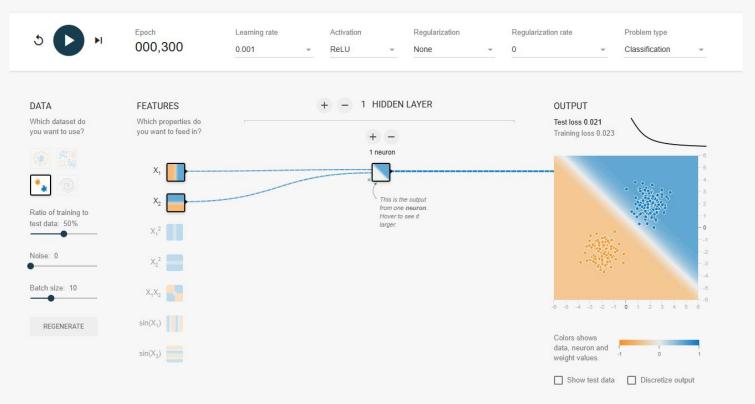
Observation

Les deux classes sont séparées de façon linéaire.

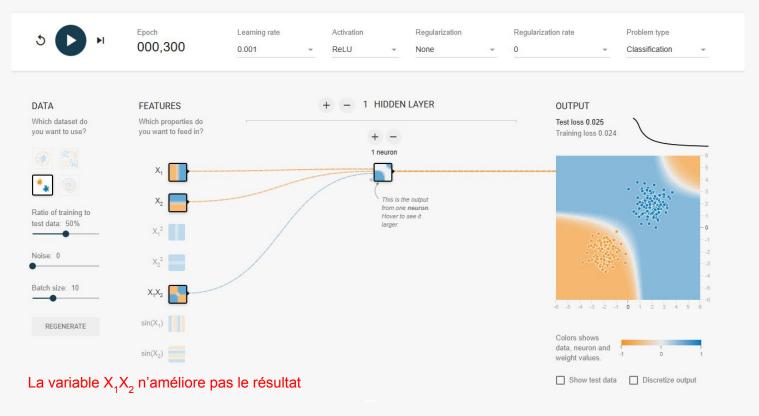
Les variables les plus susceptibles de permettre au réseau de neurones de converger sont donc X_1 , X_2 .

Choix des variables

Variables : X₁ et X₂

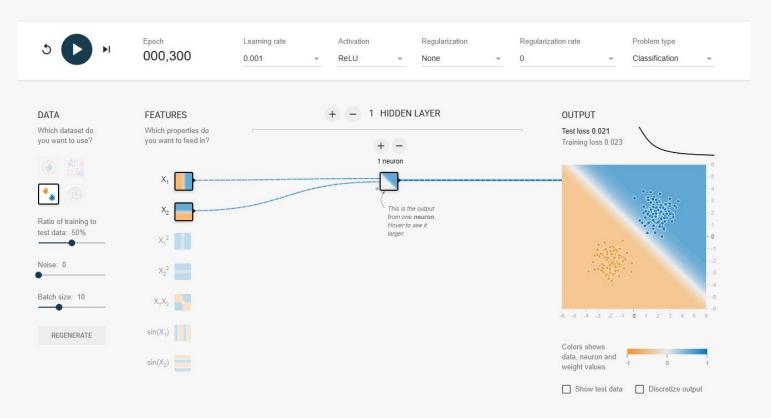


Variables : X_1 , X_2 et X_1X_2

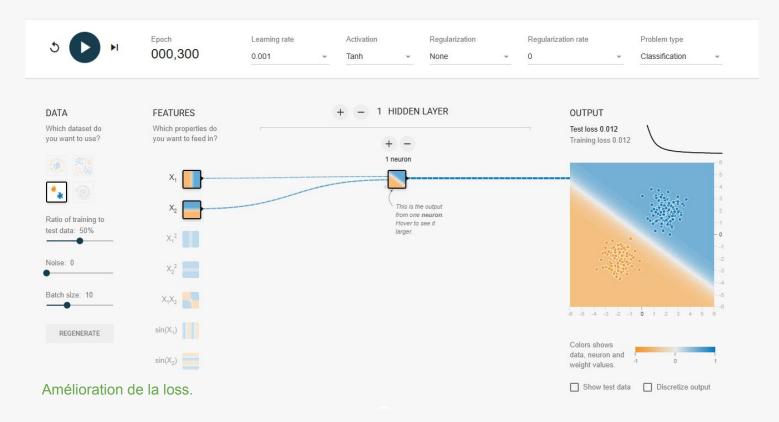


Choix de la fonction d'activation

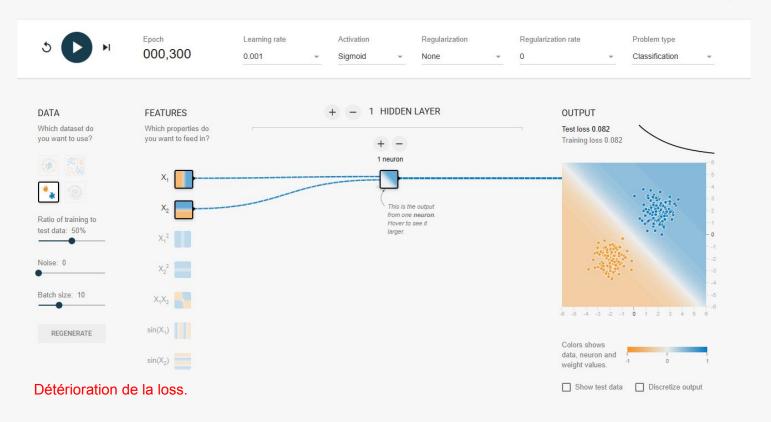
Activation: ReLU



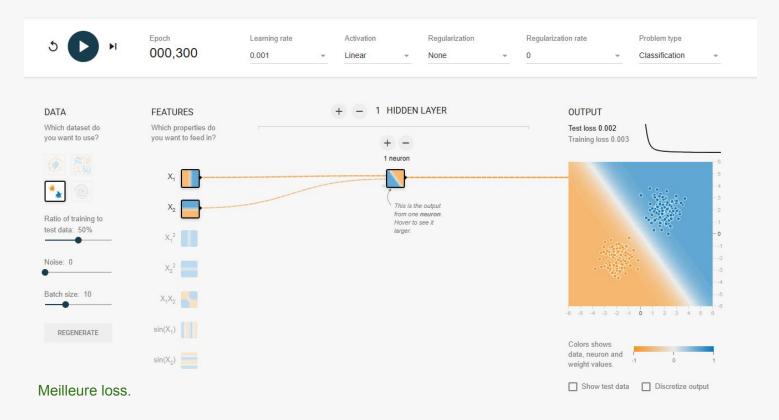
Activation: Tanh



Activation: Sigmoïd

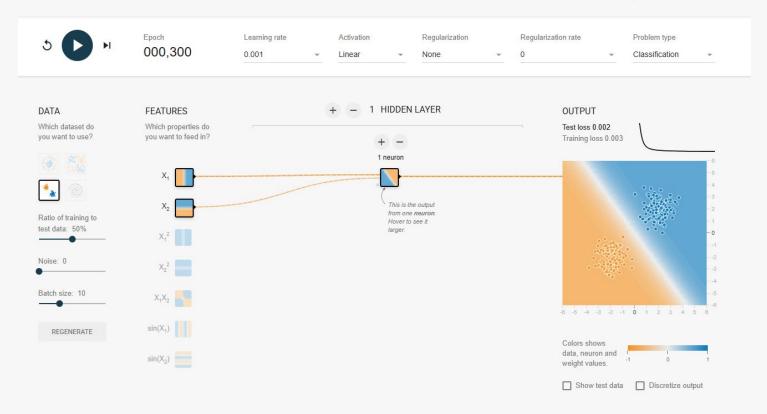


Activation: Linear

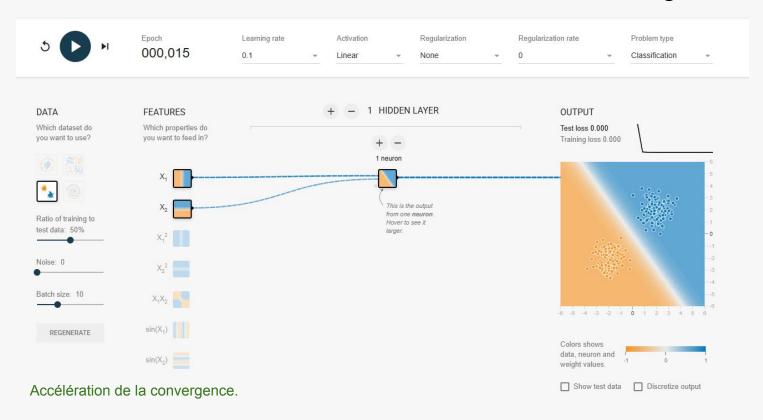


Choix du learning rate

Learning Rate: 0.001

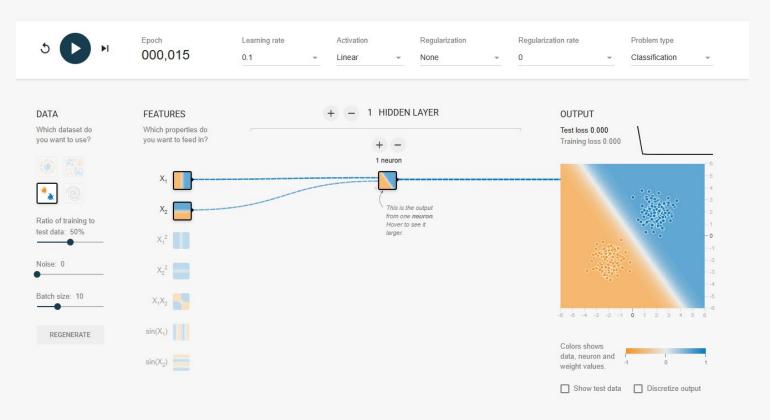


Learning Rate: 0.1

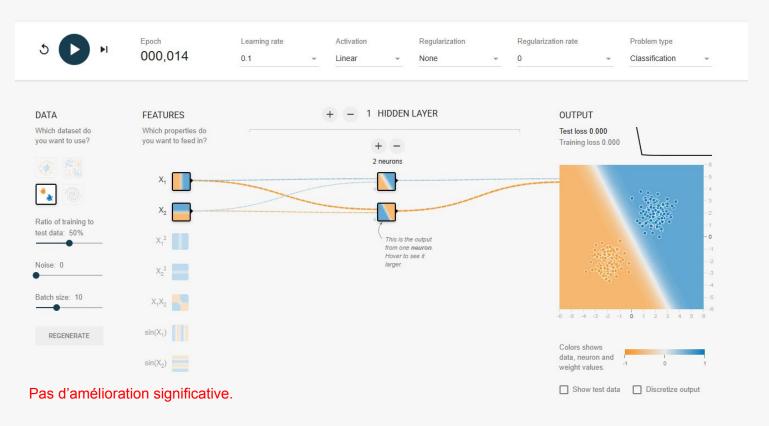


Choix du nombre de neurones

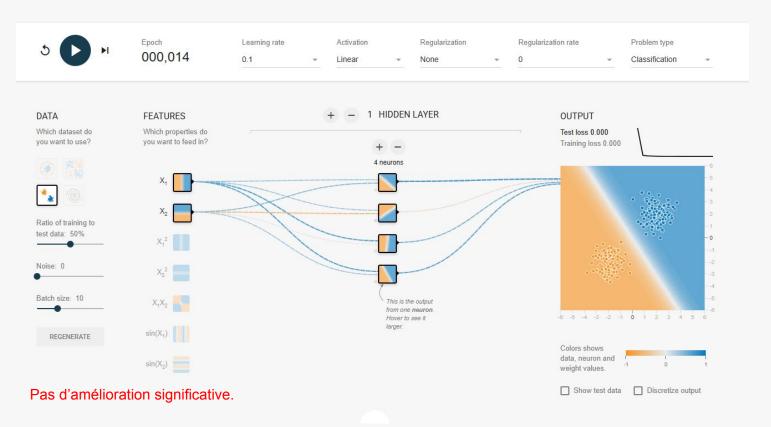
Nombre de neurones : 1



Nombre de neurones : 2



Nombre de neurones: 4



Nombre de neurones : 8



Conclusions

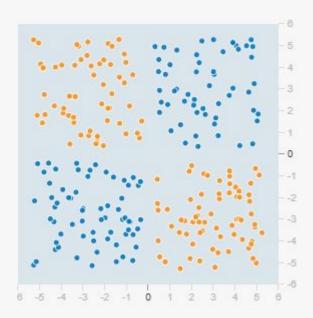
Dans le cadre d'une classification binaire de données linéairement séparables, nous savons que le perceptron est adapté. C'est donc sans trop de surprise que l'on constate qu'un seul neurone suffit pour venir à bout de la classification de cette distribution de points.

Le meilleur choix de variables est X_1 et X_2 .

La fonction d'activation la plus adaptée est la fonction Linear.

La diminution du learning rate permet de faire converger le modèle plus rapidement.

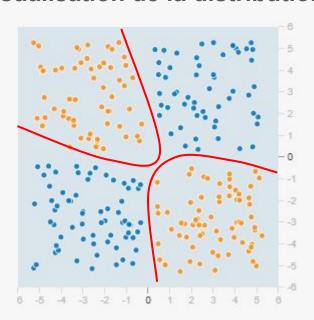
Visualisation de la distribution



Observation

Chaque classe est répartie dans deux cadrans. La séparation n'est pas linéaire.

Visualisation de la distribution



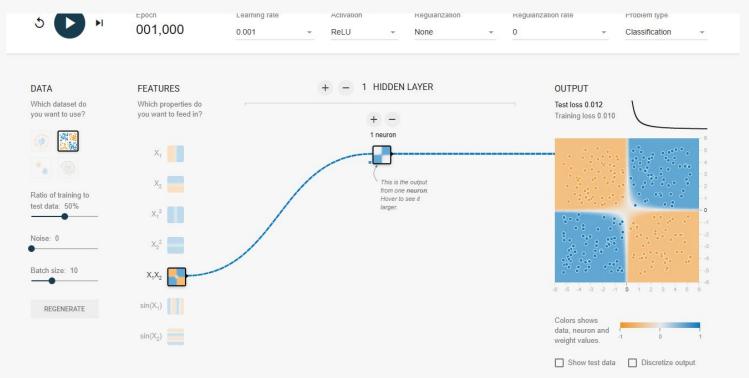
Observation

Chaque classe est répartie dans deux cadrans. La séparation est de forme hyperbolique.

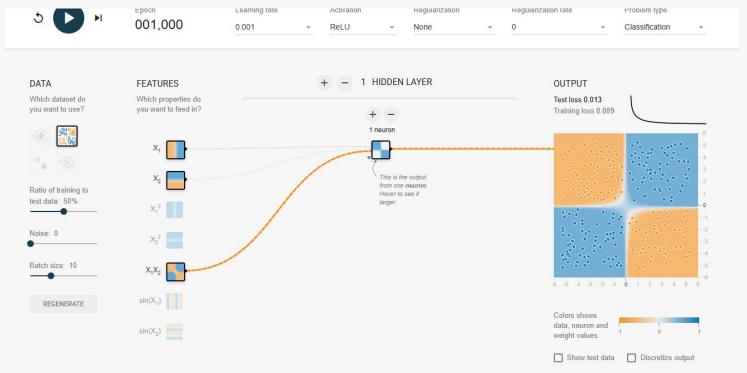
Les variables les plus susceptibles de permettre au réseau de neurones de converger sont donc X_1X_2 .

Choix des variables

Variables: X₁X₂

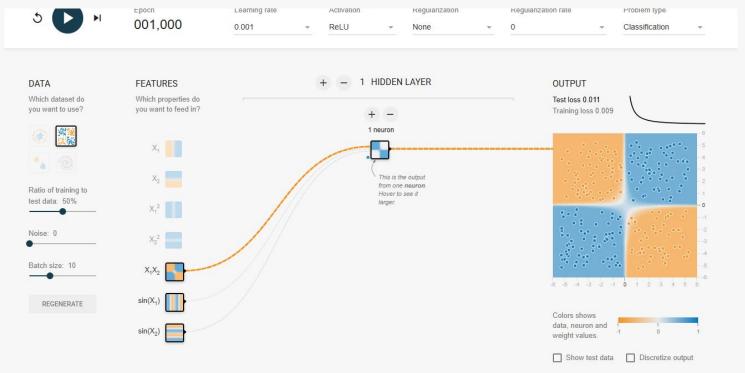


Variables : X₁, X₂ et X₁X₂



Les nouvelles variables n'ont pas d'influence.

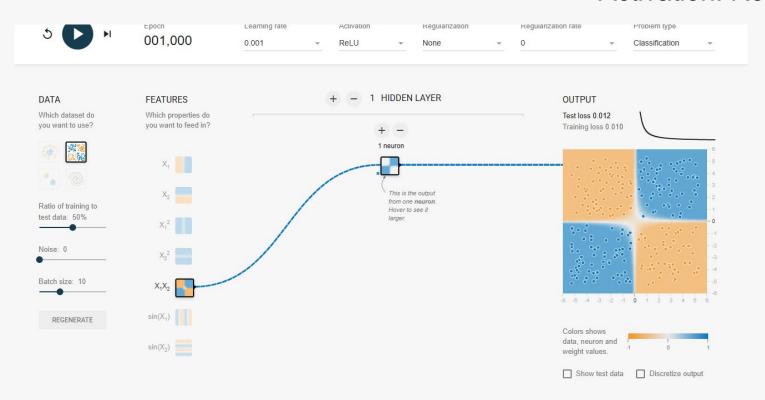
Variables : $sin(X_1)$, $sin(X_2)$ et X_1X_2



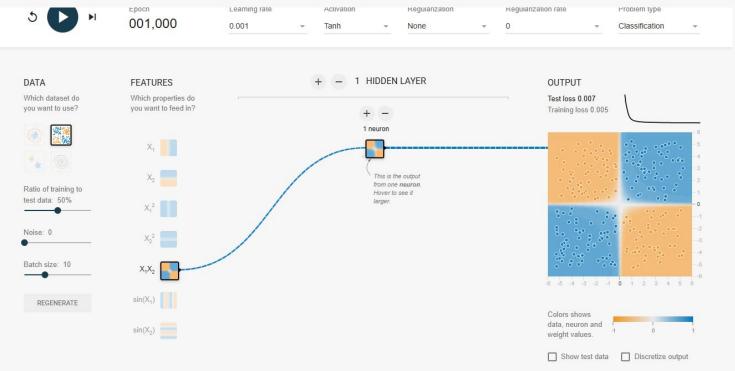
Les nouvelles variables n'ont pas d'influence.

Choix de la fonction d'activation

Activation: ReLu

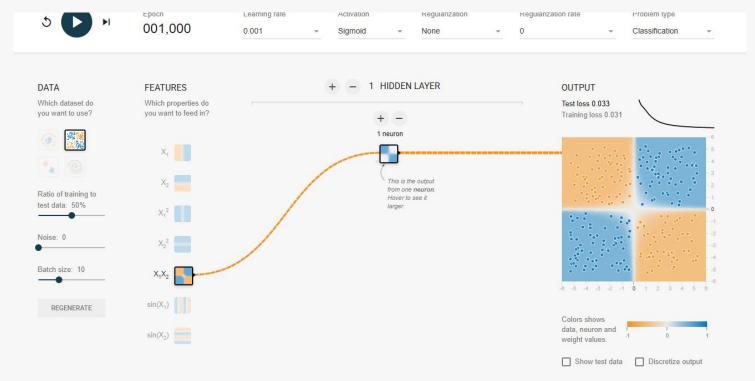


Activation: Tanh



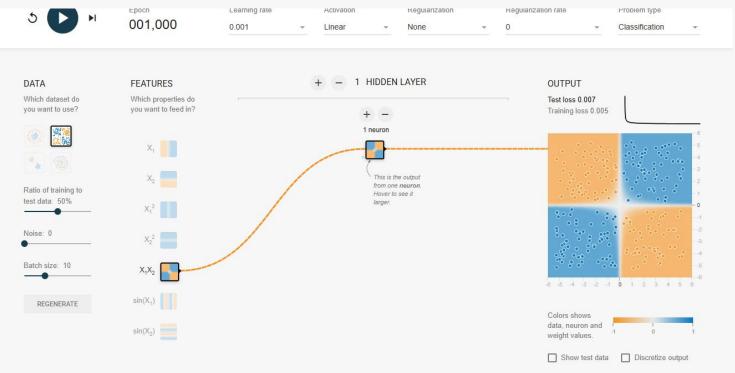
Amélioration de la loss.

Activation: Sigmoïd



Augmentation de la loss.

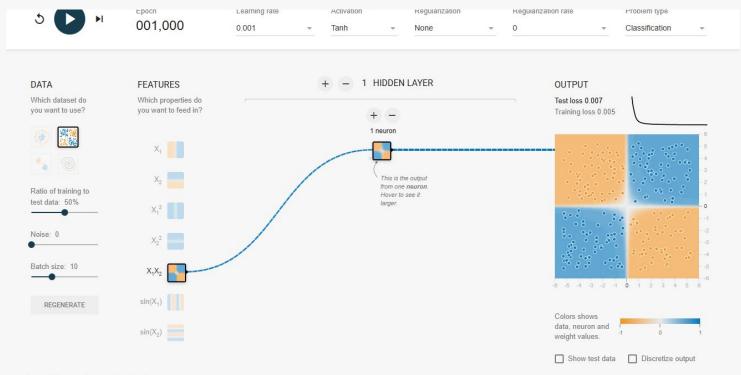
Activation: Linear



Même résultat que Tanh.

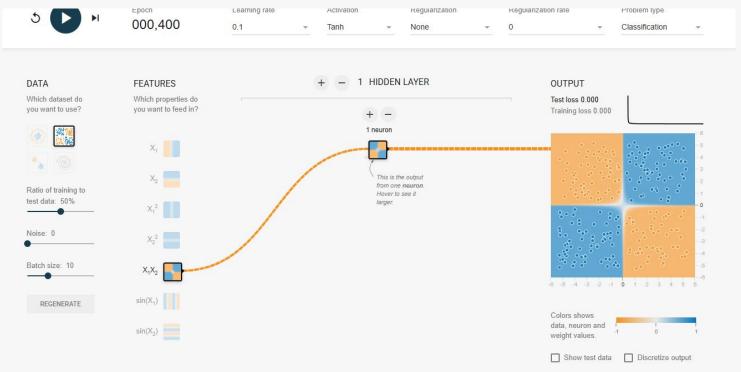
Choix du learning rate

Learning Rate: 0.001



Amélioration de la loss.

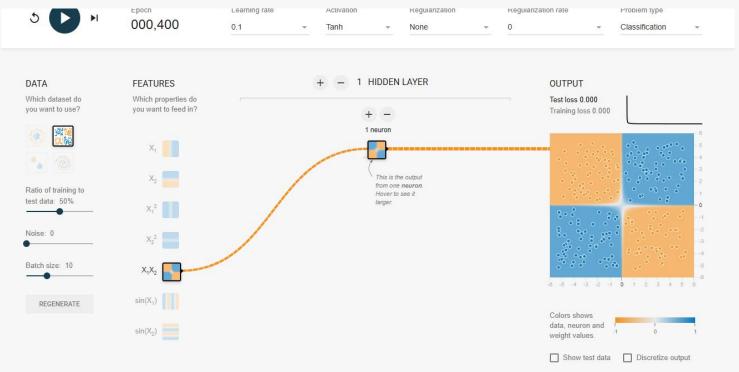
Learning Rate: 0.1



Accélération de la convergence et amélioration de la loss.

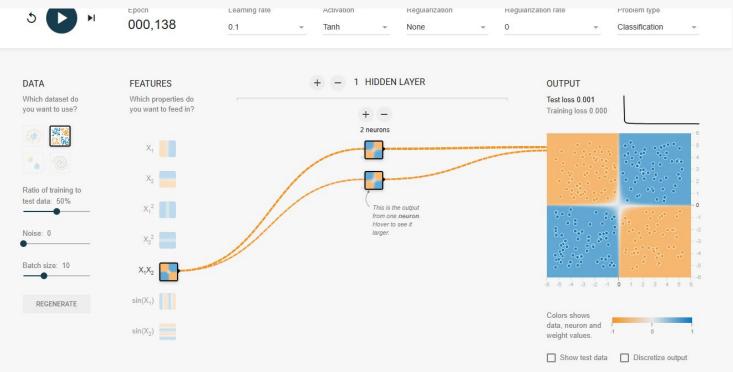
Choix du nombre de neurones

Nombre de neurones: 1



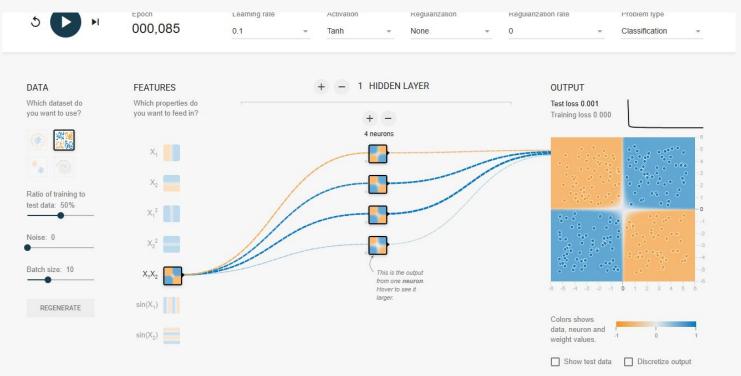
Accélération de la convergence et amélioration de la loss.

Nombre de neurones: 2



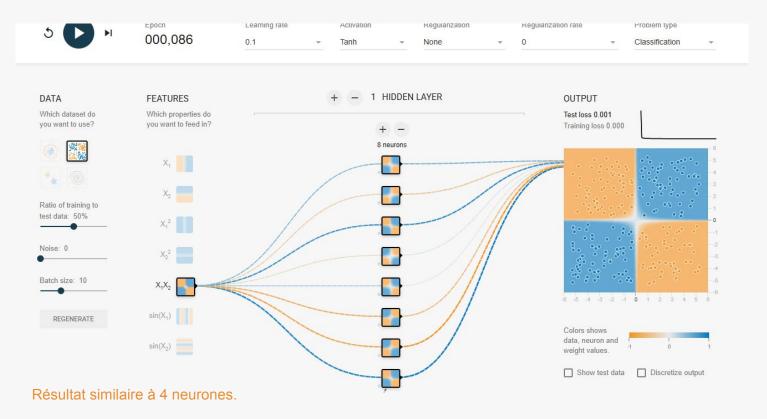
Accélération de la convergence.

Nombre de neurones: 4



Accélération de la convergence.

Nombre de neurones: 8



Conclusions

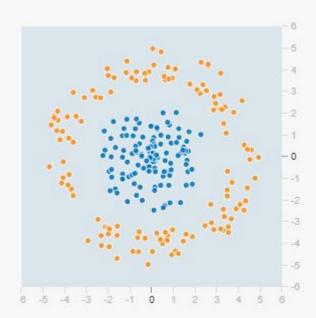
Le meilleur choix de variables est X_1X_2 .

La fonction d'activation les plus adaptées sont les fonctions Tanh et Linear qui donnent des résultats équivalents.

Le nombre de neurones optimal est 4.

La diminution du learning rate permet de faire converger le modèle plus rapidement.

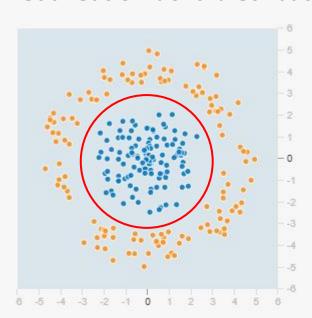
Visualisation de la distribution



Observation

Les classes sont séparables par un cercle.

Visualisation de la distribution



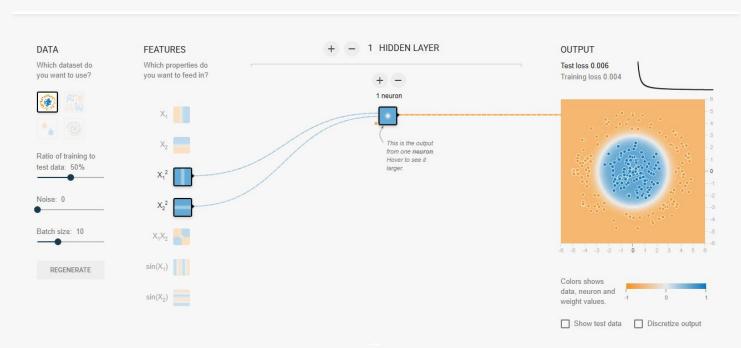
Observation

Les classes sont séparables par un cercle.

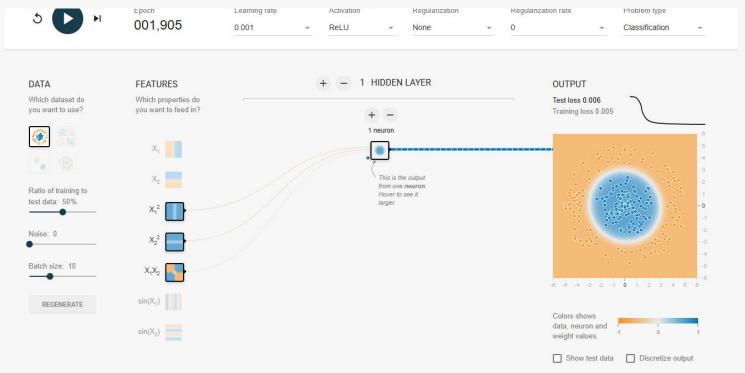
Les variables les plus adaptées sont probablement X_1^2 et X_2^2 .

Choix des variables

Variables : X₁² et X₂²



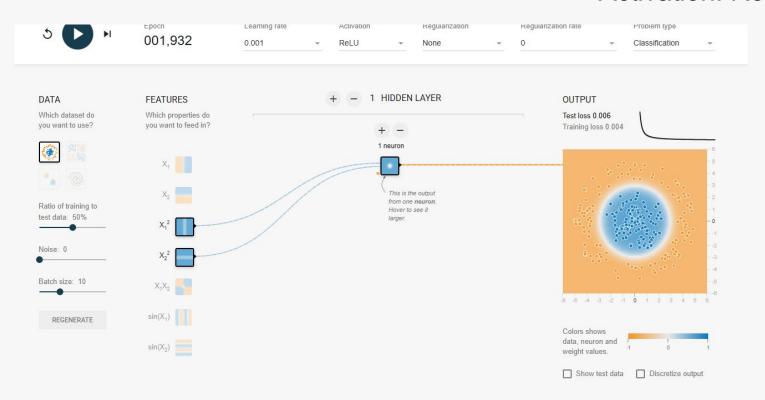
Variables : X_1^2 , X_2^2 et X_1X_2



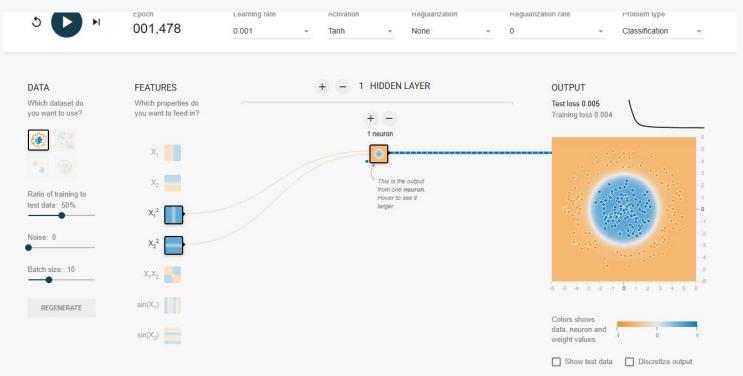
La nouvelle variable n'a pas d'influence.

Choix de la fonction d'activation

Activation: ReLu

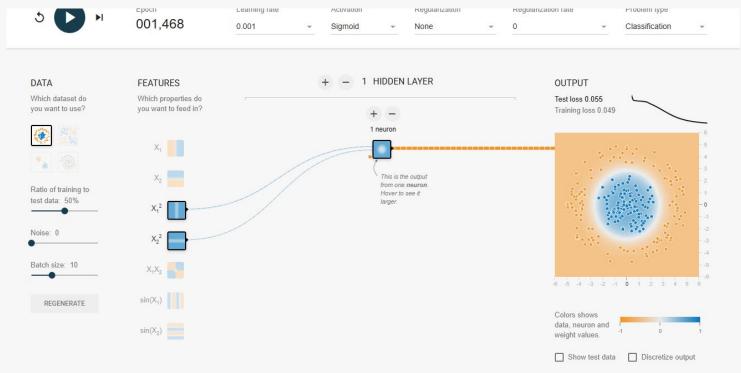


Activation: Tanh



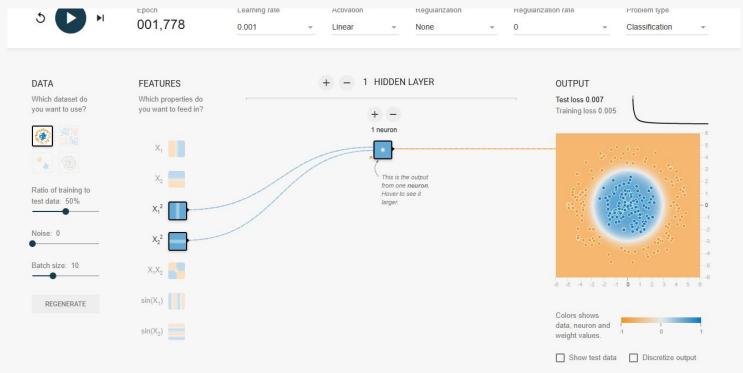
La convergence est plus rapide.

Activation: Sigmoïd



Augmentation de la loss.

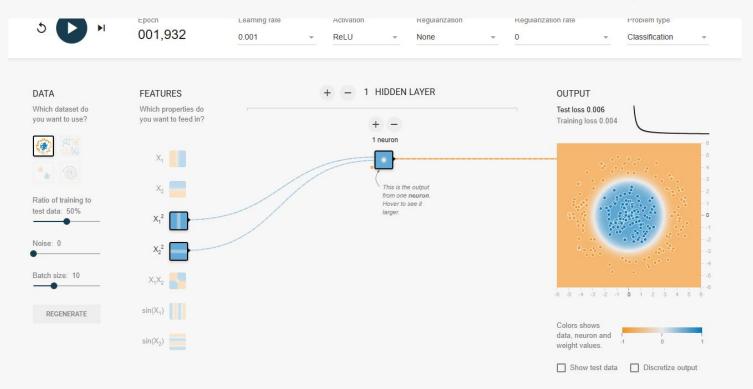
Activation: Linear



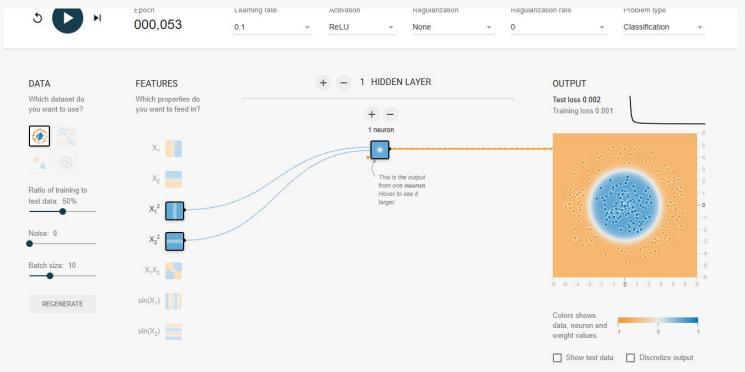
Vitesse de convergence et loss équivalentes à ReLu.

Choix du learning rate

Learning Rate: 0.001



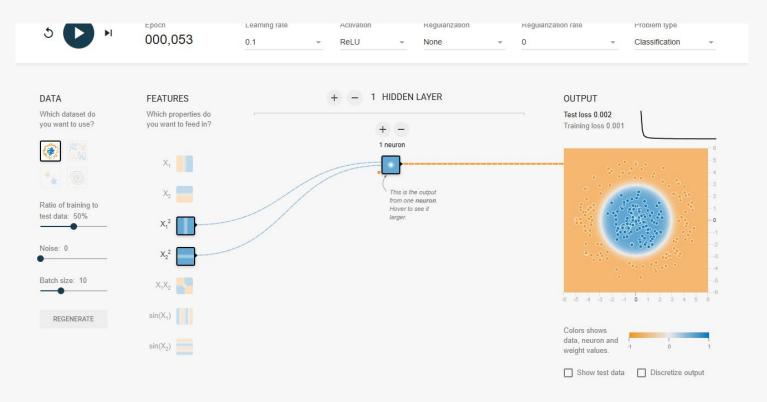
Learning Rate: 0.1



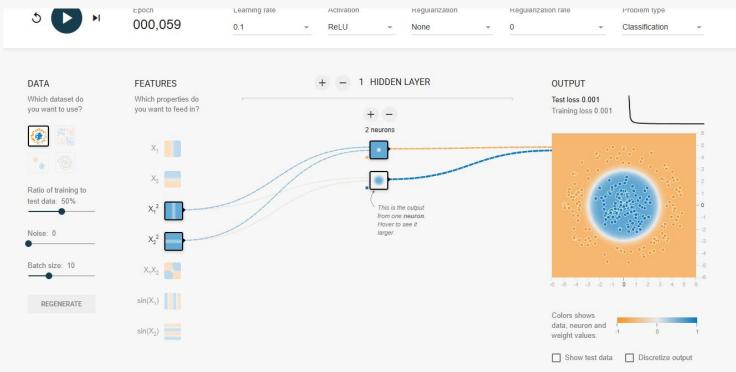
Accélération de la convergence et amélioration de la loss.

Choix du nombre de neurones

Nombre de neurones: 1

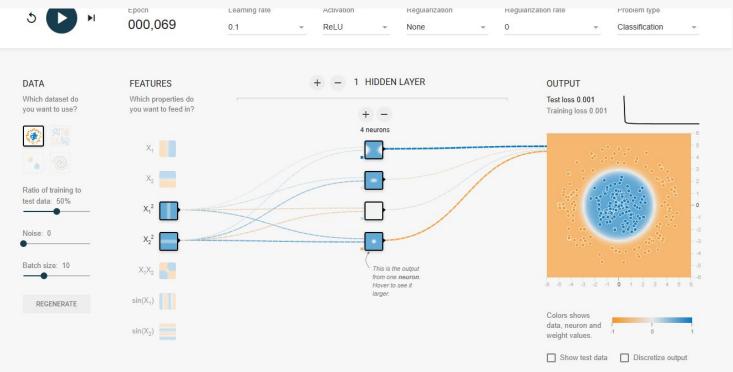


Nombre de neurones: 2



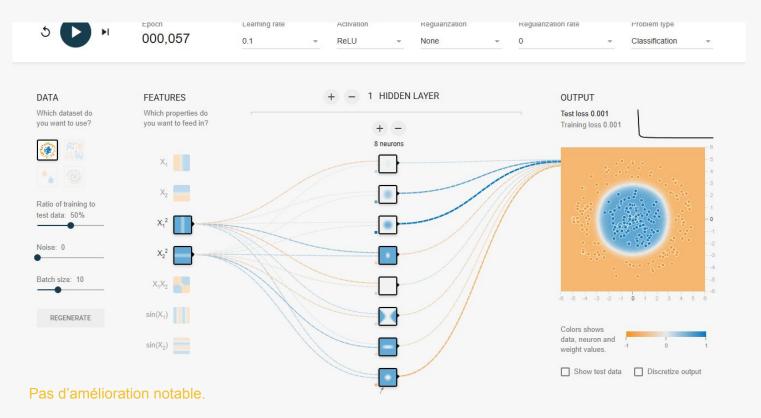
Amélioration de la loss.

Nombre de neurones: 4



Pas d'amélioration notable.

Nombre de neurones: 8



Conclusions

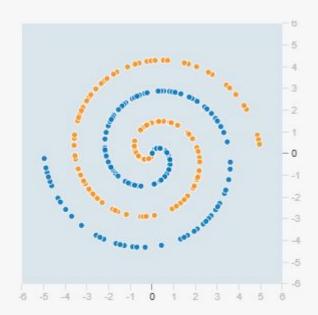
Le meilleur choix de variables est X_1^2 et X_2^2 .

La fonction d'activation la plus adaptées est Tanh.

Le nombre de neurones optimal est 2.

La diminution du learning rate permet de faire converger le modèle plus rapidement.

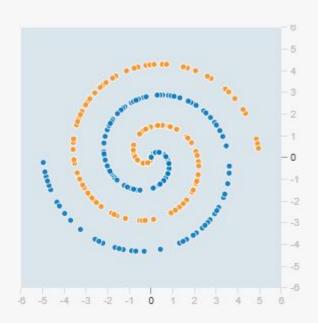
Visualisation de la distribution



Observation

Les classes sont séparables par une spirale.

Visualisation de la distribution



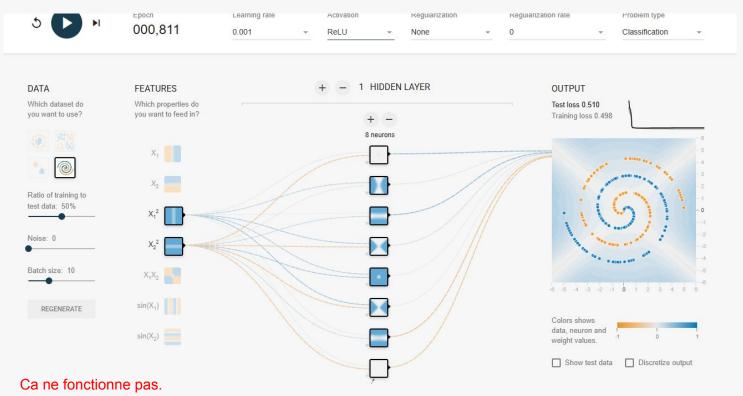
Observation

Les classes sont séparables par une spirale.

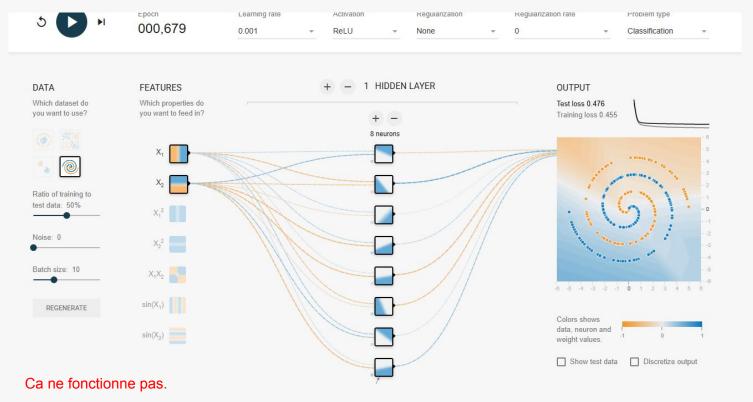
On va essayer directement avec un couche de 8 neurones.

Choix des variables

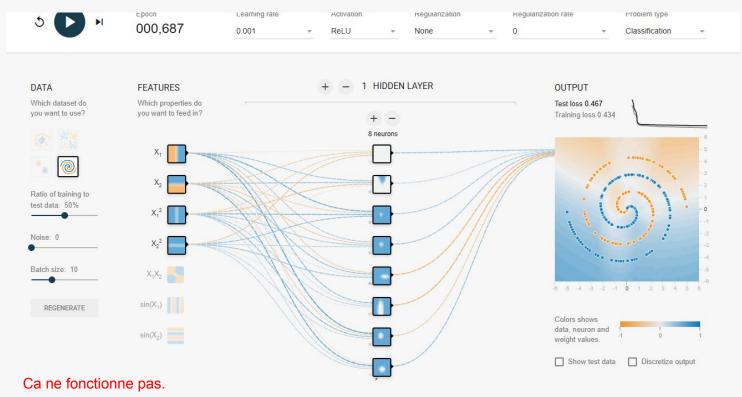
Variables : X₁²et X₂²



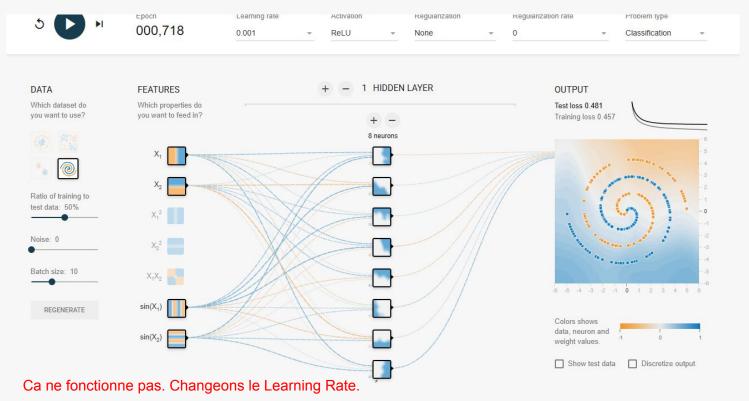
Variables : X₁ et X₂



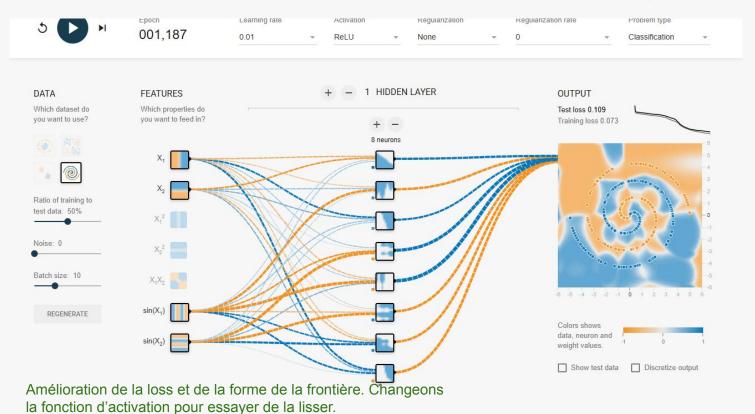
Variables : X₁, X₂, X₁²et X₂²



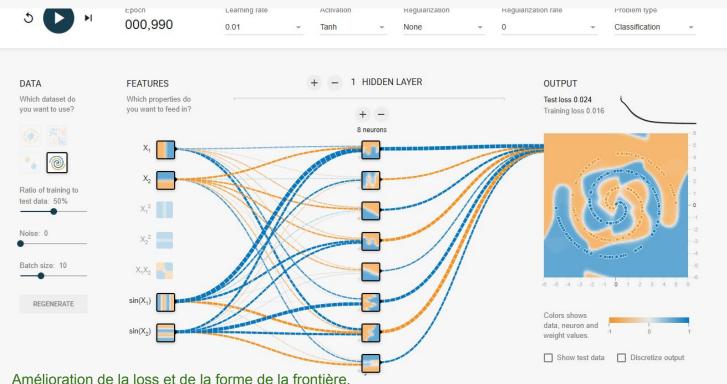
Variables : X_1 , X_2 , $sin(X_1)$ et $sin(X_2)$



Learning Rate: 0.01



Activation: Tanh



Amelioration de la loss et de la forme de la frontiere. Augmentons le nombre de couches de neurones.

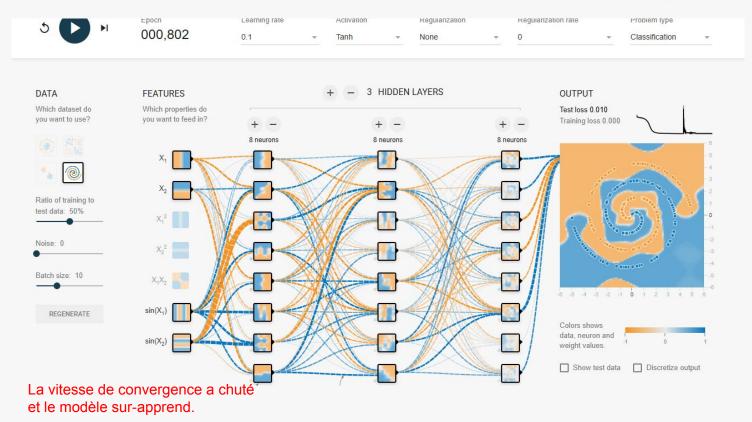
Nombre de couches: 2



Nombre de couches: 3



Learning Rate: 0.1



Conclusions

Le meilleur choix de variables est X_1 , X_2 , $sin(X_1)$ et $sin(X_2)$.

La fonction d'activation la plus adaptées est Tanh.

Le nombre de couches de neurones optimal est 3.

La diminution du learning rate permet de faire converger le modèle plus rapidement mais il ne faut pas que sa valeur soit trop élevée.